

# 일원배치법과 선형모형

서울시립대 통계학과

2021-04-06



# 차 례

|              |                                  |           |
|--------------|----------------------------------|-----------|
| <b>제 1 장</b> | <b>일원배치 모형과 최소제곱법</b>            | <b>1</b>  |
| 제 1 절        | 최소제곱법과 제약조건 . . . . .            | 1         |
| 제 2 절        | 선형모형과 제약 조건 . . . . .            | 3         |
| <b>제 2 장</b> | <b>추정 가능한 함수</b>                 | <b>7</b>  |
| 제 1 절        | 일원배치법에 추정가능한 모수 . . . . .        | 7         |
| 제 2 절        | 추정가능한 모수의 함수 . . . . .           | 7         |
| 제 3 절        | 예제 . . . . .                     | 8         |
| <b>제 3 장</b> | <b>일원배치에서의 추정: R 실습</b>          | <b>11</b> |
| 제 1 절        | 예제 3.1 . . . . .                 | 11        |
| 제 2 절        | 자료의 생성 . . . . .                 | 11        |
| 제 3 절        | 선형모형의 적합(set-to-zero) . . . . .  | 12        |
| 제 4 절        | 선형모형의 적합 (sum-to-zero) . . . . . | 14        |
| 제 5 절        | 분산분석 . . . . .                   | 16        |



# 서문

일원배치 실험계획법의 목적은 서로 다른 처리의 효과가 같은지 다른지 알아보는 것이다. 따라서 분산분석표를 이용하여 다음과 같은 가설을 검정한다.

$$H_0 : \alpha_1 = \alpha_2 = \cdots = \alpha_a$$

만약 위의 귀무가설을 기각하지 못했다면 처리의 효과들이 모두 같으므로 더 이상의 추론은 소용이 없다. 하지만 만약 귀무가설을 기각하게 되면 처리 효과들이 어떻게 다른지 추론해 보아야 한다.

교과서 3.5 절과 강의노트에서 각 처리에 대한 반응값의 평균  $\mu + \alpha_i$ 와 각 처리간의 차이  $\alpha_i - \alpha_j$ 에 대한 신뢰구간과 가설 검정을 다루었다.

이 강의에서는 일원배치에서 처리 효과를 비교하는 통계적 방법들에 대하여 더욱 자세하게 알아보려고 한다.



교과서에서는 반응 변수를  $x$  로 표현하였는데 이 강의에서는  $y$  로 표시할 것이다.

---

이 노트는 분산분석 후에 여러 개의 수준에 대한 비교를 할 때 통계적 방법에 대한 이론과 예제에 대한 강의자료입니다. 이 노트에 있는 R 프로그램을 실행하려면 다음과 같은 패키지들이 필요하다.

```
library(dplyr)
library(tidyr)
library(ggplot2)
library(agricolae)
library(emmeans)
```



## 제 1 장

# 일원배치 모형과 최소제곱법

### 제 1 절 최소제곱법과 제약조건

이제 일원배치법에 대한 통계적 모형에서 모수에 대한 추정을 생각해 보자.

$$y_{ij} = \mu + \alpha_i + e_{ij} \quad (1.1)$$

추정해야할 모수는 전체 평균  $\mu$ 와 각 그룹의 처리 효과  $\alpha_i$  그리고 분산  $\sigma_E^2$ 이다. 전체 평균과 그룹의 효과는 오차제곱합(Sum of Square Error; SSE)을 최소로 하는 모수를 추정하는 최소제곱법(Least Square method; LS)으로 구할 수 있다.

$$\min_{\mu, \alpha_1, \dots, \alpha_a} \sum_{i=1}^a \sum_{j=1}^r (y_{ij} - \mu - \alpha_i)^2 = \min_{\mu, \alpha_1, \dots, \alpha_a} SSE \quad (1.2)$$

위의 오차제곱합이 모든 모수에 대하여 미분가능한 이차식이므로 최소제곱 추정량은 제곱합을 모수에 대하여 미분하고 0 으로 놓아 방정식을 풀어서 얻을 수 있다.

오차제곱합을 모수  $\mu$ 와  $\alpha_1, \alpha_2, \dots, \alpha_a$  로 미분하여 0 으로 놓은 방정식은 다음과 같다.

$$\begin{aligned} \frac{\partial}{\partial \mu} SSE &= -2 \sum_{i=1}^a \sum_{j=1}^r (y_{ij} - \mu - \alpha_i) = 0 \\ \frac{\partial}{\partial \alpha_i} SSE &= -2 \sum_{j=1}^r (y_{ij} - \mu - \alpha_i) = 0, \quad i = 1, 2, \dots, a \end{aligned}$$

위의 방정식을 정리하면 다음과 같은  $a + 1$ 개의 방정식을 얻는다.

$$\mu + \frac{\sum_{i=1}^a \alpha_i}{a} = \bar{y} \quad (1.3)$$

$$\mu + \alpha_1 = \bar{y}_1. \quad (1.4)$$

$$\mu + \alpha_2 = \bar{y}_2. \quad (1.5)$$

$$\dots\dots \quad (1.6)$$

$$\mu + \alpha_a = \bar{y}_a. \quad (1.7)$$

$$(1.8)$$

위의 방정식에서 첫 번째 방정식은 다른  $a$ 개의 방정식을 모두 합한 방정식과 같다. 따라서 모수는  $a+1$ 개이지만 실제 방정식의 개수는  $a$ 개이므로 유일한 해가 얻어지지 않는다. 따라서 유일한 해를 구하려면 하나의 제약조건이 필요하며 일반적으로 다음과 같은 두 개의 조건 중 하나를 사용한다.

### 1.1 set-to-zero condition

첫 번째 효과  $\alpha_1$ 를 0으로 놓는 조건을 주는 것이다 ( $\alpha_1 = 0$ ). set-to-zero 조건 하에서는 다음과 같은 추정량이 얻어진다.

$$\hat{\mu} = \bar{y}_{1.}, \quad \hat{\alpha}_1 = 0, \quad \hat{\alpha}_i = \bar{y}_{i.} - \bar{y}_{1.}, \quad i = 2, \dots, a \quad (1.9)$$

### 1.2 sum-to-zero condition

처리들의 효과의 합은 0이라는 조건을 주는 것이다 ( $\sum_{i=1}^a \alpha_i = 0$ ). sum-to-zero 조건에서는 계수의 추정치가 다음과 같이 주어진다.

$$\hat{\mu} = \bar{\bar{y}}, \quad \hat{\alpha}_i = \bar{y}_{i.} - \bar{\bar{y}}, \quad i = 1, 2, \dots, a \quad (1.10)$$

여기서 유의할 점은 개별 모수들의 추정량은 조건에 따라서 달라지지만 집단의 평균을 나타내는 모수  $\mu + \alpha_i$ 에 대한 추정량은 언제나 같다.

$$\widehat{\mu + \alpha_i} = \hat{\mu} + \hat{\alpha}_i = \bar{y}_{i.}$$

만약에 자료를 아래와 같은 평균 모형으로 나타낼 경우에는 각 평균  $\mu_i$ 는 각 그룹의 표본 평균으로 추정된다.

$$y_{ij} = \mu_i + e_{ij}$$

평균 모형에서 각 그룹의 모평균에 대한 최소제곱 추정량은  $\hat{\mu}_i = \bar{y}_{i.}$ 이며 이는 주효과 모형에서의 추정량과 동일하다.



또한 모형에 관계없이 오차항의 분산  $\sigma_E^2$  에 대한 추정량은 다음과 같이 주어진다.

$$\hat{\sigma}_E^2 = \frac{\sum_i \sum_j (y_{ij} - \hat{\mu} - \hat{\alpha}_i)^2}{a(r-1)}$$

## 제 2 절 선형모형과 제약 조건

일원배치 모형 (1.1)를 다음과 같은 벡터를 이용한 선형모형(linear model, regression model) 형태로 나타내고자 한다.

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e} \quad (1.11)$$

위의 선형모형식의 요소  $\mathbf{y}$ ,  $\mathbf{X}$ ,  $\boldsymbol{\beta}$ ,  $\mathbf{e}$ 는 다음과 같은 벡터와 행렬로 표현된다.

$$\begin{bmatrix} y_{11} \\ y_{12} \\ \vdots \\ y_{1r} \\ y_{21} \\ y_{22} \\ \vdots \\ y_{2r} \\ \vdots \\ y_{a1} \\ y_{a2} \\ \vdots \\ y_{ar} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & \cdot & \cdot & 0 \\ 1 & 1 & 0 & \cdot & \cdot & 0 \\ 1 & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 1 & 0 & \cdot & \cdot & 0 \\ 1 & 0 & 1 & \cdot & \cdot & 0 \\ 1 & 0 & 1 & \cdot & \cdot & 0 \\ 1 & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 1 & \cdot & \cdot & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & \cdot & \cdot & 1 \\ 1 & 0 & 0 & \cdot & \cdot & 1 \\ 1 & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & \cdot & \cdot & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_a \end{bmatrix} + \begin{bmatrix} e_{11} \\ e_{12} \\ \vdots \\ e_{1r} \\ e_{21} \\ e_{22} \\ \vdots \\ e_{2r} \\ \vdots \\ e_{a1} \\ e_{a2} \\ \vdots \\ e_{ar} \end{bmatrix} \quad (1.12)$$

이제 위에서 논의한 최소제곱법을 선형 모형 (1.11) 에 적용하면 다음과 같이 표현할 수 있다.

$$\min_{\mu, \alpha_1, \dots, \alpha_a} \sum_{i=1}^a \sum_{j=1}^r (y_{ij} - \mu - \alpha_i)^2 = \min_{\boldsymbol{\beta}} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^t (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) \quad (1.13)$$

최소제곱법의 기준을 만족하는 계수  $\boldsymbol{\beta}$ 는 다음과 같은 정규방정식(normal equation)의 해(solution)이다.

$$\mathbf{X}^t \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^t \mathbf{y} \quad (1.14)$$

정규방정식 (1.14) 을 일원배치의 선형모형식 (1.12) 에 나타난  $\mathbf{y}$ ,  $\mathbf{X}$ 로 이용하여 나타내면 다음과 같다.

$$\begin{bmatrix} ar & r & r & \cdot & \cdot & r \\ r & r & 0 & \cdot & \cdot & 0 \\ r & 0 & r & \cdot & \cdot & 0 \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ r & 0 & 0 & \cdot & \cdot & r \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \cdot \\ \cdot \\ \alpha_a \end{bmatrix} = \begin{bmatrix} ar\bar{y} \\ r\bar{y}_1. \\ r\bar{y}_2. \\ \cdot \\ \cdot \\ r\bar{y}_a. \end{bmatrix} \quad (1.15)$$

정규방정식 (1.15) 는 위에서 구한 최소제곱법에서 유도된 방정식 (1.8) 과 같다.

여기서 유의할 점은 선형모형식 (1.12) 의 계획행렬  $\mathbf{X}$  가 완전 계수(full rank) 행렬이 아니다. 계획행렬  $\mathbf{X}$  의 첫 번째 열은 다른 열을 합한 것과 같다. 또한 정규 방정식 (1.15)에서  $\mathbf{X}^t \mathbf{X}$  행렬도 완전계수 행렬이 아니다. 따라서  $\mathbf{X}^t \mathbf{X}$  행렬의 역행렬은 존재하지 않는다.

이러한 이유로 모수에 대한 유일한 추정량이 존재하지 않기 때문에 앞에서 언급한 제약 조건을 고려해야 정규 방정식을 풀 수 있다.

## 2.1 Set-to-zero 조건에서의 모형과 최소제곱 추정량

만약 Set-to-zero 조건을 가정한다면 모수에서  $\alpha_1$ 을 제외하고 선형모형식 (1.12)를 다음과 같이 다시 표현할 수 있다.

효과  $\alpha_1$ 을 0 으로 놓는다는 것은  $\alpha_1$ 을 추정할 필요가 없으므로 모수벡터  $\beta$  에서  $\alpha_1$ 를 빼고 계획행렬에서도 대응하는 열을 제거하는 것이다.

$$\begin{bmatrix} y_{11} \\ y_{12} \\ \vdots \\ y_{1r} \\ y_{21} \\ y_{22} \\ \vdots \\ y_{2r} \\ \vdots \\ y_{a1} \\ y_{a2} \\ \vdots \\ y_{ar} \end{bmatrix} = \begin{bmatrix} 1 & 0 & \cdot & \cdot & 0 \\ 1 & 0 & \cdot & \cdot & 0 \\ 1 & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & \cdot & \cdot & 0 \\ 1 & 1 & \cdot & \cdot & 0 \\ 1 & 1 & \cdot & \cdot & 0 \\ 1 & \vdots & \vdots & \vdots & \vdots \\ 1 & 1 & \cdot & \cdot & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & \cdot & \cdot & 1 \\ 1 & 0 & \cdot & \cdot & 1 \\ 1 & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & \cdot & \cdot & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_2 \\ \alpha_3 \\ \vdots \\ \alpha_a \end{bmatrix} + \begin{bmatrix} e_{11} \\ e_{12} \\ \vdots \\ e_{1r} \\ e_{21} \\ e_{22} \\ \vdots \\ e_{2r} \\ \vdots \\ e_{a1} \\ e_{a2} \\ \vdots \\ e_{ar} \end{bmatrix} \quad (1.16)$$

이제 수정된 모형식 (1.16) 에 최소제곱법을 적용하여 정규방정식을 구하면 다음과 같은 방정식을 얻는다.

$$\begin{bmatrix} ar & r & r & \cdot & \cdot & r \\ r & r & 0 & \cdot & \cdot & 0 \\ r & 0 & r & \cdot & \cdot & 0 \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ r & 0 & 0 & \cdot & \cdot & r \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_2 \\ \alpha_3 \\ \cdot \\ \cdot \\ \alpha_a \end{bmatrix} = \begin{bmatrix} ar\bar{y} \\ r\bar{y}_2. \\ r\bar{y}_3. \\ \cdot \\ \cdot \\ r\bar{y}_a. \end{bmatrix} \quad (1.17)$$

위의 정규방정 (1.17) 를 풀면 위에서 언급한 sum-to-zero 조건에서 구해지는 모수의 추정량 (1.9)를 얻을 수 있다.

## 2.2 Sum-to-zero 조건에서의 모형과 최소제곱 추정량

이제 Sum-to-zero 조건에서 모수의 추정에 대해 알아보자. 조건  $\sum_{i=1}^a \alpha_i = 0$  조건을 마지막 모수  $\alpha_a$ 에 대하여 표현하면 다음과 같다.

$$\alpha_a = -\alpha_1 - \alpha_2 - \cdots - \alpha_{a-1}$$

따라서 마지막 처리  $\alpha_a$  에 대한 관측값에 대한 모형은 다음과 같아 쓸 수 있다.

$$y_{aj} = \mu + \alpha_a + e_{aj} = \mu + (-\alpha_1 - \alpha_2 - \cdots - \alpha_{a-1}) + e_{ij}$$

이러한 결과를 모형방정식에 반영한다. 즉, 모수벡터  $\beta$  에서  $\alpha_a$ 를 제거하고 계획행렬에 위의 마지막 처리에 대한 효과식을 반영하면 다음과 같은 선형모형식을 얻는다.

$$\begin{bmatrix} y_{11} \\ y_{12} \\ \vdots \\ y_{1r} \\ y_{21} \\ y_{22} \\ \vdots \\ y_{2r} \\ \vdots \\ y_{a1} \\ y_{a2} \\ \vdots \\ y_{ar} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & \cdot & \cdot & 0 \\ 1 & 1 & 0 & \cdot & \cdot & 0 \\ 1 & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 1 & 0 & \cdot & \cdot & 0 \\ 1 & 0 & 1 & \cdot & \cdot & 0 \\ 1 & 0 & 1 & \cdot & \cdot & 0 \\ 1 & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 1 & \cdot & \cdot & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & \cdot & \cdot & 1 \\ 1 & 0 & 0 & \cdot & \cdot & 1 \\ 1 & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & \cdot & \cdot & 1 \\ 1 & 0 & 0 & \cdot & \cdot & 1 \\ 1 & -1 & -1 & \cdot & \cdot & -1 \\ 1 & -1 & -1 & \cdot & \cdot & -1 \\ 1 & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & -1 & -1 & \cdot & \cdot & -1 \\ 1 & -1 & -1 & \cdot & \cdot & -1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_{a-1} \end{bmatrix} + \begin{bmatrix} e_{11} \\ e_{12} \\ \vdots \\ e_{1r} \\ e_{21} \\ e_{22} \\ \vdots \\ e_{2r} \\ \vdots \\ e_{a1} \\ e_{a2} \\ \vdots \\ e_{ar} \end{bmatrix} \quad (1.18)$$

이제 수정된 모형식 (1.18) 에 최소제곱법을 적용하여 정규방정식을 구하면 다음과 같은 방정식을 얻는다.

$$\begin{bmatrix} ar & 0 & 0 & \cdot & \cdot & 0 \\ 0 & 2r & r & \cdot & \cdot & r \\ 0 & r & 2r & \cdot & \cdot & r \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ 0 & r & r & \cdot & \cdot & 2r \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_2 \\ \alpha_3 \\ \cdot \\ \cdot \\ \alpha_{a-1} \end{bmatrix} = \begin{bmatrix} ar\bar{y} \\ r\bar{y}_2 - r\bar{y}_a \\ r\bar{y}_3 - r\bar{y}_a \\ \cdot \\ \cdot \\ r\bar{y}_{a-1} - r\bar{y}_a \end{bmatrix} \quad (1.19)$$

위의 정규방정 (1.19) 를 풀면 위에서 언급한 sum-to-zero 조건에서 구해지는 모수의 추정량 (1.10)를 얻을 수 있다.

## 제 2 장

# 추정 가능한 함수

### 제 1 절 일원배치법에 추정가능한 모수

앞 절에서 보았듯이 일원배치법을 선형 모형식으로 표현하는 경우 평균에 대한 모수는 모두  $a + 1$  개가 있다.

$$\mu, \alpha_1, \alpha_2, \dots, \alpha_a$$

하지만 모형식에서 계획행렬  $\mathbf{X}$ 가 완전 계수 행렬이 아니기 때문에 1개의 제약 조건을 가정하고 모수를 추정하였다. 하지만 제약 조건이 달라지면 각 모수의 추정량이 달라지기 때문에 각 모수는 유일한 값으로 추정이 불가능하다.

이렇게 각 모수들은 제약 조건에 따라서 유일하게 추정이 불가능하지만 앞 절에서 보았듯이  $\mu + \alpha_i$ 에 대한 추정량은 제약조건에 관계없이 표본 평균  $\bar{y}_i$ 으로 동일하게 추정되어 진다.

그러면 어떤 모수들은 유일하게 추정이 불가능하고 어떤 모수들이 유일하게 추정이 가능할까?

이제 제약조건이 달라도 유일하게 추정이 가능한 모수들의 형태를 살펴보자.

### 제 2 절 추정가능한 모수의 함수

선형모형  $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$ 에서 계획행렬  $\mathbf{X}$ 의 계수가 완전하지 않으면 모수 벡터  $\boldsymbol{\beta}$ 는 유일한 값으로 추정할 수 없다.

이제 모수들의 선형결합  $\psi = \mathbf{c}^t\boldsymbol{\beta}$ 를 고려하자.

예를 들어 일원배치 모형에서는 다음과 같은 모수들의 선형결합을 고려하는 것이다.

$$\psi = \mathbf{c}^t\boldsymbol{\beta} = c_0\mu + c_1\alpha_1 + c_2\alpha_2 + \dots + c_a\alpha_a$$

위에서 본 것처럼 하나의 모수  $\alpha_1$ 에 대한 유일한 추정은 불가능하다.

$$\alpha_1 = (0)\mu + (1)\alpha_1 + (0)\alpha_2 + \cdots + (0)\alpha_a$$

하지만 모수의 조합  $\mu + \alpha_2$  은 유일한 추정이 가능하다.

$$\mu + \alpha_1 = (1)\mu + (1)\alpha_1 + (0)\alpha_2 + \cdots + (0)\alpha_a$$

이제 문제는 선형조합  $\psi = \mathbf{c}^t \boldsymbol{\beta}$  에서 계수들  $c_0, c_1, \dots, c_a$ 가 어떤 값을 가지는 경우 유일한 추정이 가능한 지 알아내는 것이다.

이제  $\psi = \mathbf{c}^t \boldsymbol{\beta}$  에 대한 유일한 추정량  $\hat{\psi}$  이 있다고 가정하자. 선형 모형에서 추정량  $\hat{\psi}$ 의 형태는 관측값에 대한 선형함수가 되어야 한다. 따라서 추정량을  $\hat{\psi} = \mathbf{a}^t \mathbf{y}$  로 나타낼 수 있다. 이제 추정량  $\hat{\psi}$ 의 기대값은  $\psi = \mathbf{c}^t \boldsymbol{\beta}$  이어야 하므로 다음이 성립해야 한다.

$$E(\hat{\psi}|\mathbf{X}) = E(\mathbf{a}^t \mathbf{y}|\mathbf{X}) = \mathbf{a}^t E(\mathbf{y}|\mathbf{X}) = \mathbf{a}^t \mathbf{X} \boldsymbol{\beta} = \mathbf{c}^t \boldsymbol{\beta}$$

위의 식에서 가장 마지막 두 항의 관계를 보면 다음이 성립해야 한다.

$$\mathbf{a}^t \mathbf{X} = \mathbf{c}^t \quad \text{equivalently} \quad \mathbf{c} = \mathbf{X}^t \mathbf{a} \quad (2.1)$$

즉 추정가능한 모수의 조합  $\psi = \mathbf{c}^t \boldsymbol{\beta}$ 에서 계수 벡터  $\mathbf{c}$  는 계획행렬에 있는 행들의 선형 조합으로 표시되어야 한다는 것이다. 이렇게 유일하게 추정이 가능한 모수의 조합을 **추정가능한 함수(estimable function)**이라고 한다.

### 제 3 절 예제

2개의 수준이 있고 반복이 2번 있는 일원배치 ( $a = 2, r = 2$ ) 에 대한 선형모형 (1.12)을 생각해보자. 이 경우 계획행렬  $\mathbf{X}$  과 모수벡터  $\boldsymbol{\beta}$  는 다음과 같다.

$$\mathbf{X} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \end{bmatrix} \quad \boldsymbol{\beta} = \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \end{bmatrix} \quad (2.2)$$

이제 유일하게 추정 가능한 모수 조합은 어떤 형태일까?

$$\psi = \mathbf{c}^t \boldsymbol{\beta} = c_0 \mu + c_1 \alpha_1 + c_2 \alpha_2$$

다음으로 임의의 벡터  $\mathbf{a}$  에 대하여  $\mathbf{X}^t \mathbf{a}$ 의 형태를 보자.

$$\begin{aligned}\mathbf{X}^t \mathbf{a} &= \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ a_3 \\ a_4 \end{bmatrix} \\ &= (a_1 + a_2) \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} + (a_3 + a_4) \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}\end{aligned}$$

위의 식에서 유의할 점은 벡터  $\mathbf{a}$ 는 임의로 주어진 벡터이다.

따라서 유일하게 추정 가능한 모수의 선형조합  $\psi = \mathbf{c}^t \boldsymbol{\beta}$  에 대한 계수 벡터  $\mathbf{c}^t = [c_0 \ c_1 \ c_2]$  는 계획행렬  $\mathbf{X}$ 의 유일한 행들의 선형 조합으로 구성되어야 한다.

$$\mathbf{c} = \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = a_1 \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} + a_2 \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \quad (2.3)$$

- 처리의 효과를 나타내는 모수  $\alpha_i$ 는 추정이 불가능하다.

예를 들어 첫 번째 처리에 대한 효과 모수  $\alpha_1$  를 선형조합으로 나타내면

$$\alpha_1 = c_0 \mu + c_1 \alpha_1 + c_2 \alpha_2 = (0) \mu + (1) \alpha_1 + (0) \alpha_2$$

따라서  $\mathbf{c}^t = [0 \ 1 \ 0]$ 을 만들수 있는 계수  $a_1$ 과  $a_2$ 를 찾아야 하는데 불가능하다. 따라서 모수  $\alpha_1$  은 추정 불가능하다.

$$\mathbf{c} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} = a_1 \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} + a_2 \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

- 처리의 평균을 나타내는 모수의 조합  $\mu + \alpha_i$ 는 추정이 가능하다.

예를 들어 모수 조합  $\mu + \alpha_1$  를 선형조합으로 나타내면

$$\mu + \alpha_1 = c_0 \mu + c_1 \alpha_1 + c_2 \alpha_2 = (1) \mu + (1) \alpha_1 + (0) \alpha_2$$

따라서  $\mathbf{c}^t = [1 \ 1 \ 0]$ 을 만들수 있는 계수  $a_1 = 1$ 과  $a_2 = 0$  이므로 추정이 가능하다.

$$\mathbf{c} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} = (1) \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} + (0) \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

- 처리 효과의 차이를 나타내는 모수의 조합  $\alpha_1 - \alpha_2$ 는 추정이 가능하다.

$$\alpha_1 - \alpha_2 = c_0\mu + c_1\alpha_1 + c_2\alpha_2 = (0)\mu + (1)\alpha_1 + (-1)\alpha_2$$

따라서  $\mathbf{c}^t = [0 \ 1 \ -1]$ 을 만들수 있는 계수  $a_1 = 1$ 과  $a_2 = -1$  이므로 추정이 가능하다.

$$\mathbf{c} = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix} = (1) \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} + (-1) \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$



## 제 3 장

# 일원배치에서의 추정: R 실습

### 제 1 절 예제 3.1

4개의 서로 다른 원단업체에서 직물을 공급받고 있다. 공급한 직물의 굵힘에 대한 저항력을 알아보기 위하여 각 업체마다 4개의 제품을 랜덤하게 선택하여 ( $a = 4$ ,  $r = 4$ ) 일원배치법에 의하여 마모도 검사를 실시하였다.

### 제 2 절 자료의 생성

```
company<- as.factor(rep(c(1:4), each=4))
response<- c(1.93, 2.38, 2.20, 2.25,
             2.55, 2.72, 2.75, 2.70,
             2.40, 2.68, 2.32, 2.28,
             2.33, 2.38, 2.28, 2.25)
df31<- data.frame(company=company, response= response)
df31
```

| ##   | company | response |
|------|---------|----------|
| ## 1 | 1       | 1.93     |
| ## 2 | 1       | 2.38     |
| ## 3 | 1       | 2.20     |
| ## 4 | 1       | 2.25     |
| ## 5 | 2       | 2.55     |
| ## 6 | 2       | 2.72     |
| ## 7 | 2       | 2.75     |
| ## 8 | 2       | 2.70     |
| ## 9 | 3       | 2.40     |

```
## 10      3      2.68
## 11      3      2.32
## 12      3      2.28
## 13      4      2.33
## 14      4      2.38
## 15      4      2.28
## 16      4      2.25
```

각 수준에 대한 표본 평균을 구해보자.

```
df31s <- df31 %>% group_by(company) %>% summarise(mean=mean(response), median= median(response), sd=s
df31s
```

```
## # A tibble: 4 x 6
##   company mean median    sd   min   max
## * <fct>   <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 1       2.19  2.22 0.189  1.93  2.38
## 2 2       2.68  2.71 0.0891 2.55  2.75
## 3 3       2.42  2.36 0.180  2.28  2.68
## 4 4       2.31  2.30 0.0572 2.25  2.38
```

### 제 3 절 선형모형의 적합(set-to-zero)

이제 자료를 다음과 같은 선형 모형으로 적합해 보자. 선형 모형의 적합은 `lm()` 함수를 사용한다.

$$y_{ij} = \mu + \alpha_i + e_{ij}$$

여기서 선형식의 모수와 R의 변수는 다음과 같은 관계를 가진다,

| 선형식의 모수    | R의 변수       |
|------------|-------------|
| $\mu$      | (Intercept) |
| $\alpha_1$ | company1    |
| $\alpha_2$ | company2    |
| $\alpha_3$ | company3    |
| $\alpha_4$ | company4    |

```
fit1 <- lm(response~company,data=df31)
summary(fit1)
```

```
##
## Call:
## lm(formula = response ~ company, data = df31)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.2600 -0.0700  0.0150  0.0625  0.2600
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   2.1900     0.0705   31.06  7.8e-13 ***
## company2      0.4900     0.0997    4.91  0.00036 ***
## company3      0.2300     0.0997    2.31  0.03971 *
## company4      0.1200     0.0997    1.20  0.25198
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.141 on 12 degrees of freedom
## Multiple R-squared:  0.687, Adjusted R-squared:  0.609
## F-statistic: 8.78 on 3 and 12 DF, p-value: 0.00235
```

위에서 적합한 결과를 보면 평균  $\mu$ 와 4개의 처리  $\alpha_1, \alpha_2, \alpha_3, \alpha_4$  가 모형에 있지만 모수의 추정량은 평균 (intercept)과 3개의 모수(company2, company3, company4)만 추정량이 주어진다.

R 에서 옵션을 지정하지 않고 함수 lm()으로 선형모형을 적합하는 경우 set-to-zero 조건을 적용하며 자료에 나타난 처리의 수준들 중 순위가 가장 낮은 수준의 효과를 0으로 지정한다 (company1=0 ). set-to-zero 조건을 강제로 지정하려면 다음과 같은 명령문을 먼저 실행한다.

```
options(contrasts=c("contr.treatment", "contr.poly"))
```

위의 결과를 보면 (Intercept)에 대한 추정량이 첫 번째 처리 company1의 평균과 같은 것을 알 수 있다.

set-to-zero 조건에서의 계획행렬은 다음과 같이 볼 수 있다.

```
model.matrix(fit1)
```

```
##      (Intercept) company2 company3 company4
## 1              1         0         0         0
## 2              1         0         0         0
## 3              1         0         0         0
## 4              1         0         0         0
## 5              1         1         0         0
```

```
## 6      1      1      0      0
## 7      1      1      0      0
## 8      1      1      0      0
## 9      1      0      1      0
## 10     1      0      1      0
## 11     1      0      1      0
## 12     1      0      1      0
## 13     1      0      0      1
## 14     1      0      0      1
## 15     1      0      0      1
## 16     1      0      0      1
## attr(,"assign")
## [1] 0 1 1 1
## attr(,"contrasts")
## attr(,"contrasts")$company
## [1] "contr.treatment"
```

이제 각 처리 평균에 대한 추정값  $\widehat{\mu + \alpha_i}$ 을 구해보자.

```
emmeans(fit1, "company")
```

```
##  company emmean      SE df lower.CL upper.CL
##  1          2.19 0.0705 12      2.04      2.34
##  2          2.68 0.0705 12      2.53      2.83
##  3          2.42 0.0705 12      2.27      2.57
##  4          2.31 0.0705 12      2.16      2.46
##
## Confidence level used: 0.95
```

이 경우 처리 평균에 대한 추정값은 산술 평균과 동일하게 나온다.

## 제 4 절 선형모형의 적합 (sum-to-zero)

이제 일원배치 모형에서 sum-to-zero 조건을 적용하여 모수를 추정해 보자. sum-to-zero 조건을 적용하려면 다음과 같은 명령어를 실행해야 한다.

```
options(contrasts=c("contr.sum", "contr.poly"))
```

이제 다시 선형모형을 적합하고 추정결과를 보자.

```
fit2 <- lm(response~company,data=df31)
summary(fit2)
```

```
##
## Call:
## lm(formula = response ~ company, data = df31)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.2600 -0.0700  0.0150  0.0625  0.2600
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   2.4000     0.0353   68.08 < 2e-16 ***
## company1     -0.2100     0.0611   -3.44  0.00490 **
## company2      0.2800     0.0611    4.59  0.00063 ***
## company3      0.0200     0.0611    0.33  0.74889
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.141 on 12 degrees of freedom
## Multiple R-squared:  0.687, Adjusted R-squared:  0.609
## F-statistic: 8.78 on 3 and 12 DF, p-value: 0.00235
```

이제 sum-to-zero 조건에 따라서 위의 set-to-zero 결과와 모수의 추정값이 다르게 나타나는 것을 알 수 있다. 마지막 모수  $\text{company4}(\alpha_4)$ 는 sum-to-zero 조건을 이용하여 다음과 같은 관계를 이용하여 구할 수 있다.

$$\alpha_4 = -(\alpha_1 + \alpha_2 + \alpha_3)$$

sum-to-zero 조건에서의 계획행렬은 다음과 같이 볼 수 있다.

```
model.matrix(fit2)
```

```
##      (Intercept) company1 company2 company3
## 1             1         1         0         0
## 2             1         1         0         0
## 3             1         1         0         0
## 4             1         1         0         0
## 5             1         0         1         0
```

```
## 6      1      0      1      0
## 7      1      0      1      0
## 8      1      0      1      0
## 9      1      0      0      1
## 10     1      0      0      1
## 11     1      0      0      1
## 12     1      0      0      1
## 13     1     -1     -1     -1
## 14     1     -1     -1     -1
## 15     1     -1     -1     -1
## 16     1     -1     -1     -1
## attr(,"assign")
## [1] 0 1 1 1
## attr(,"contrasts")
## attr(,"contrasts")$company
## [1] "contr.sum"
```

이제 각 처리 평균에 대한 추정값  $\widehat{\mu + \alpha_i}$ 을 구해보면 set-to-zero 조건에서의 추정값과 동일함을 알 수 있다.

```
emmeans(fit2, "company")
```

```
## company emmean      SE df lower.CL upper.CL
## 1      2.19 0.0705 12      2.04      2.34
## 2      2.68 0.0705 12      2.53      2.83
## 3      2.42 0.0705 12      2.27      2.57
## 4      2.31 0.0705 12      2.16      2.46
##
## Confidence level used: 0.95
```

## 제 5 절 분산분석

분산분석의 결과는 어떠한 제약 조건에서도 동일하다.

```
res1 <- anova(fit1)
res1
```

```
## Analysis of Variance Table
##
## Response: response
##      Df Sum Sq Mean Sq F value Pr(>F)
```

```
## company      3  0.524  0.1747    8.78 0.0024 **
## Residuals 12  0.239  0.0199
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
res2<- anova(fit2)
res2
```

```
## Analysis of Variance Table
##
## Response: response
##           Df Sum Sq Mean Sq F value Pr(>F)
## company      3  0.524  0.1747    8.78 0.0024 **
## Residuals 12  0.239  0.0199
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```