

# 행렬대수 1 - 사영과 QR 분해

시립대학교 통계학과

2019년 6월 3일

## 1 두 벡터의 사영

선형독립인 두 벡터  $\mathbf{a}_1$ 과  $\mathbf{a}_2$ 가 있다고 하자. 벡터  $\mathbf{a}_1$ 과 같은 방향을 가지면서 벡터  $\mathbf{a}_2$ 에 가장 가까운 벡터를  $proj_{\mathbf{a}_1}(\mathbf{a}_2)$ 라고 정의하고 이를 벡터  $\mathbf{a}_1$  방향으로 벡터  $\mathbf{a}_2$ 의 사영(projection)이라고 부른다.

그러면 이러한 사영은 어떻게 구할 수 있나? 벡터  $\mathbf{a}_2$ 의 사영은 벡터  $\mathbf{a}_1$  방향에 있으므로 어떤 실수  $c$ 가 있어서 다음과 같이 표시할 수 있다.

$$proj_{\mathbf{a}_1}(\mathbf{a}_2) = c\mathbf{a}_1$$

이제 사영  $c\mathbf{a}_1$ 과 벡터  $\mathbf{a}_2$ 의 거리  $d(c)$ 를 생각하면 다음과 같다.

$$\begin{aligned} d^2(c) &= \|\mathbf{a}_2 - c\mathbf{a}_1\|^2 \\ &= (\mathbf{a}_2 - c\mathbf{a}_1)^t(\mathbf{a}_2 - c\mathbf{a}_1) \\ &= \mathbf{a}_2^t\mathbf{a}_2 - 2c\mathbf{a}_2^t\mathbf{a}_1 + c^2\mathbf{a}_1^t\mathbf{a}_1 \end{aligned}$$

위에서  $\|\mathbf{a}\|$ 는 벡터  $\mathbf{a}$ 의 길이를 나타낸다.

$$d(\mathbf{a}) = \|\mathbf{a}\| = \sqrt{\mathbf{a}^t\mathbf{a}}$$

상수  $c$ 는 거리  $d(c)$ 를 최소로 만드는 수이다.  $d^2(c)$ 은  $c$ 에 대하여 미분 가능한 2차 함수이며 아래로 볼록한 함수이므로 이를 미분하여  $c$ 를 구할 수 있다.

$$\frac{\partial d^2(c)}{\partial c} = -2\mathbf{a}_2^t\mathbf{a}_1 + 2c\mathbf{a}_1^t\mathbf{a}_1 = 0$$

위의 방적식으로 부터  $c$ 를 얻고

$$c = \frac{a_2^t a_1}{a_1^t a_1}$$

다음과 같이 벡터  $a_1$  방향으로 벡터  $a_2$  의 사영을 나타낼 수 있다.

$$proj_{a_1}(a_2) = \frac{a_2^t a_1}{a_1^t a_1} a_1 \quad (1)$$

이제 위의 두 벡터의 사영을 이용하면 벡터  $a_1$  과 직교하는 벡터  $\tilde{q}_2$ 를 다음과 같이 찾을 수 있다.

$$\tilde{q}_2 = a_2 - proj_{a_1}(a_2) = a_2 - \frac{a_2^t a_1}{a_1^t a_1} a_1$$

두 벡터  $a_1$ 와  $\tilde{q}_2$ 의 직교성은 다음과 같이 보일 수 있다.

$$\begin{aligned} a_1^t \tilde{q}_2 &= a_1^t \left( a_2 - \frac{a_2^t a_1}{a_1^t a_1} a_1 \right) \\ &= a_1^t a_2 - \frac{a_2^t a_1}{a_1^t a_1} a_1^t a_1 \\ &= a_1^t a_2 - a_2^t a_1 \\ &= 0 \end{aligned}$$

이제 두 벡터  $q_1$ 과  $q_2$  를 다음과 정규직교벡터로 만들 수 있다.

$$\begin{aligned} q_1 &= a_1 / \|a_1\| \\ q_2 &= \tilde{q}_2 / \|\tilde{q}_2\| \end{aligned}$$

## 1.1 Gram-Schmidt 방법

서로 독립인  $n$ 차원의 벡터들이  $p$ 개 있을때

$$a_1, a_2, \dots, a_p$$

이들이 만드는 열공간을  $C$ 라고 하자.

$$S = \{ c_1 \mathbf{a}_1 + c_2 \mathbf{a}_2 + \cdots + c_p \mathbf{a}_p \mid \text{all possible real values of } c_1, c_2, \dots, c_p \} = \text{span}\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_p\} \quad (2)$$

이제 우리는 위와 동일한 열공간  $S$  만드는 정규직교 벡터들을 찾는 방법을 알아보려고 한다.

$$\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_p \quad \text{where } \mathbf{q}_i^t \mathbf{q}_j = 0, \quad \mathbf{q}_i^t \mathbf{q}_i = 1$$

그리고

$$S = \text{span}\{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_p\} = \text{span}\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_p\} \quad (3)$$

이제 앞 절의 벡터의 사영에 대한 결과를 사용하여 다음과 같은 직교하는  $p$  개의 벡터들을 축차적으로 만들어 보자.

$$\begin{aligned} \tilde{\mathbf{q}}_1 &= \mathbf{a}_1 \\ \tilde{\mathbf{q}}_2 &= \mathbf{a}_2 - \text{proj}_{\tilde{\mathbf{q}}_1}(\mathbf{a}_2) \\ \tilde{\mathbf{q}}_3 &= \mathbf{a}_3 - \text{proj}_{\tilde{\mathbf{q}}_1}(\mathbf{a}_3) - \text{proj}_{\tilde{\mathbf{q}}_2}(\mathbf{a}_3) \\ \tilde{\mathbf{q}}_4 &= \mathbf{a}_4 - \text{proj}_{\tilde{\mathbf{q}}_1}(\mathbf{a}_4) - \text{proj}_{\tilde{\mathbf{q}}_2}(\mathbf{a}_4) - \text{proj}_{\tilde{\mathbf{q}}_3}(\mathbf{a}_4) \\ &\dots \\ \tilde{\mathbf{q}}_p &= \mathbf{a}_p - \sum_{k=1}^p \text{proj}_{\tilde{\mathbf{q}}_k}(\mathbf{a}_p) \end{aligned} \quad (4)$$


축차적으로 만든 벡터들을 정규벡터로 만들면 원래의 벡터들  $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_p$ 이 생성하는 동일한 열공간을 만드는 정규직교 벡터  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_p$ 를 만들 수 있다.

$$\mathbf{q}_i = \tilde{\mathbf{q}}_i / \|\tilde{\mathbf{q}}_i\|, \quad i = 1, 2, \dots, p \quad (5)$$

식 (4)과 (5)의 알고리즘을 Gram-Schmidt 방법이라고 부른다.

## 2 최소제곱법과 사영

회귀계수벡터의 값을 구하는 최소제곱법의 기준을 다시 살펴보자.



**Figure 5.3** Gram-Schmidt algorithm applied to two 2-vectors  $a_1, a_2$ . *Top.* The original vectors  $a_1$  and  $a_2$ . The gray circle shows the points with norm one. *Middle left.* The orthogonalization step in the first iteration yields  $\tilde{q}_1 = a_1$ . *Middle right.* The normalization step in the first iteration scales  $\tilde{q}_1$  to have norm one, which yields  $q_1$ . *Bottom left.* The orthogonalization step in the second iteration subtracts a multiple of  $q_1$  to yield the vector  $\tilde{q}_2$ , which is orthogonal to  $q_1$ . *Bottom right.* The normalization step in the second iteration scales  $\tilde{q}_2$  to have norm one, which yields  $q_2$ .

Figure 1: "Gram-Schmidt 방법을 설명한 그림(출처:Introduction to Applied Linear Algebra by Boyd and Vandenberghe, 2019)

$$\min_{\beta} \sum_{i=1}^n (y_i - \mathbf{x}_i^t \beta)^2 = \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)^t (\mathbf{y} - \mathbf{X}\beta) \quad (6)$$

위에서  $\mathbf{X}\beta$ 는 행렬  $\mathbf{X}$ 의 열벡터로 이루어진 선형조합이다.

$$\mathbf{X}\beta = [\mathbf{a}_0 \ \mathbf{a}_1 \ \cdots \ \mathbf{a}_p] \beta = \beta_0 \mathbf{a}_0 + \beta_1 \mathbf{a}_1 + \cdots + \beta_p \mathbf{a}_p$$

따라서 최소제곱법으로 구한 회귀계수 벡터는 반응값 벡터  $\mathbf{y}$ 를 행렬  $\mathbf{X}$ 의 열벡터로 생성한 열공간에 사영(projection)하게 만드는 벡터이며

$$\hat{\beta} = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{y}$$

예측값 벡터  $\hat{\mathbf{y}}$ 는 행렬  $\mathbf{X}$ 의 열벡터로 생성한 열공간 방향으로 반응값 벡터  $\mathbf{y}$ 를 사영한 벡터이다.

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\beta} = \mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{y}$$

위에서 행렬  $\mathbf{P} = \mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t$ 를 열공간  $C(\mathbf{X})$ 의 사영행렬(projection matrix)라고 부른다.

### 3 QR 분해