

# 행렬대수 1 - 특이값 분해

시립대학교 통계학과

2019년 5월 27일

## 1 고유값과 고유벡터

$n$  차원 대칭행렬  $A$  의 고유값은 실수이며 고유벡터는 서로 직교하는 성질로부터 다음과 같은 스펙트럴 분해(spectral decomposition)가 얻어진다.

$$A = P\Lambda P^t \quad (1)$$

여기서  $\Lambda$ 는 고유값을 대각원소로 하는 대각행렬이고  $P$ 는 정규직(orthonormal) 고유벡터들의 열로 구성된 직교행렬이다.

$$Aq_k = \lambda_k q_k, \quad k = 1, 2, \dots, n$$

$$|q_k| = \sqrt{q_k^t q_k} = 1 \quad k = 1, 2, \dots, n$$

$$q_l^t q_k = 0 \quad l \neq k$$

$$P = [q_1 \ q_2 \ \dots \ q_n] \text{ and } PP^t = P^t P = I$$

$$\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$$

대칭행렬과 고유값에 대한 중요한 성질들은 다음과 같다.

- 대칭행렬  $A$ 가 비음정치 행렬이면 고유값들은 음이 아닌 실수이다.
- 만약 행렬  $A$ 가 비음정치 행렬이면 스펙트럴 분해를 통해서 다음과 같이 행렬의 곱으로 나타낼 수 있다.

$$A = P\Lambda P^t = P\Lambda^{1/2}P^t P\Lambda^{1/2}P^t = HH^t, \quad \text{where } H = P\Lambda^{1/2}P^t$$

- 또한 행렬  $A$ 가 비음정치 행렬이고 그 계수가  $r$ 이면 다음과 같이 최대열계수  $n \times r$  행렬  $L$ 으로 나타낼 수 있다.

$$A = P\Lambda P^t = P \begin{bmatrix} D_r^{1/2} \\ 0 \end{bmatrix} \begin{bmatrix} D_r^{1/2} & 0^t \end{bmatrix} P^t = LL^t$$

위에서  $\Lambda = \text{diag}\{D_r, 0\}$  이다.

또한  $A$ 가  $m \times n$  행렬이라면(정방행렬이 아닐 수도 있다)  $A^t A$ 와  $AA^t$ 는 비음정치 행렬이다.

## 2 R을 이용한 고유값과 고유벡터 계산

교과서 p381-383 R을 이용한 행렬계산 기초를 읽으세요!

### 2.1 예제 6.14

```
A = matrix(c(37, -2, -24, -2, 13, -3, -24, -3, 17),3,3)
A

##      [,1] [,2] [,3]
## [1,]  37   -2  -24
## [2,]  -2   13   -3
## [3,] -24   -3   17

eigen(A)

## eigen() decomposition
## $values
## [1] 5.300000e+01 1.400000e+01 7.105427e-15
##
## $vectors
##      [,1]      [,2]      [,3]
## [1,] 0.8320503 0.1482499 -0.5345225
## [2,] 0.0000000 -0.9636241 -0.2672612
## [3,] -0.5547002 0.2223748 -0.8017837

Lambda = diag(eigen(A)$values)
Lambda
```

```
##      [,1] [,2]      [,3]
## [1,]  53    0 0.000000e+00
## [2,]   0   14 0.000000e+00
## [3,]   0    0 7.105427e-15

P = eigen(A)$vectors
P

##      [,1]      [,2]      [,3]
## [1,] 0.8320503 0.1482499 -0.5345225
## [2,] 0.0000000 -0.9636241 -0.2672612
## [3,] -0.5547002 0.2223748 -0.8017837

P %*% t(P)

##      [,1]      [,2]      [,3]
## [1,] 1.000000e+00 5.551115e-17 -1.665335e-16
## [2,] 5.551115e-17 1.000000e+00 1.942890e-16
## [3,] -1.665335e-16 1.942890e-16 1.000000e+00

P %*% Lambda %*% t(P)

##      [,1] [,2] [,3]
## [1,]  37   -2  -24
## [2,]  -2  13   -3
## [3,] -24  -3  17
```

## 2.2 정리 6.9

```
Lambda2 = sqrt(Lambda[1:2,1:2])
Lambda2

##      [,1]      [,2]
## [1,] 7.28011 0.000000
## [2,] 0.00000 3.741657

P2 = P[,c(1,2)]
```

```

P2

##           [,1]      [,2]
## [1,]  0.8320503  0.1482499
## [2,]  0.0000000 -0.9636241
## [3,] -0.5547002  0.2223748

L = P2 %*% Lambda2
L

##           [,1]      [,2]
## [1,]  6.057418  0.5547002
## [2,]  0.0000000 -3.6055513
## [3,] -4.038278  0.8320503

L %*% t(L)

##           [,1] [,2] [,3]
## [1,]    37    -2   -24
## [2,]    -2    13    -3
## [3,]   -24    -3    17

```

### 3 특이값 분해의 정의

#### 3.1 특이값과 특이벡터

고유값과 고유벡터는 정방행렬인 경우 정의되는 것으로서 행렬이 정방행렬이 아닌 경우에는 구할 수 없다. 이제 고유값과 유사한 성질을 가지는 특이값을 일반행렬에서 정의해보자.

$A$ 가  $m \times n$  일반행렬이라고 가정하고 그 계수  $r$ 이라고 하자 ( $r(A) = r$ ). 이제 서로 직교하는  $n$ -차원의 벡터들의 집합  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 과 다른 직교하는  $m$ -차원의 벡터들의 집합  $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m$ 을 생각하자.

행렬  $A$ 의 특이값(singular values)  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ 과 왼쪽 특이벡터(left singular vectors)  $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m$  그리고 오른쪽 특이벡터(right singular vectors)  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$  는 다음과 같은 성질을 만족한다.

$$A\mathbf{v}_1 = \sigma_1\mathbf{u}_1, \quad A\mathbf{v}_2 = \sigma_2\mathbf{u}_2, \quad \dots \quad A\mathbf{v}_r = \sigma_r\mathbf{u}_r, \quad A\mathbf{v}_{r+1} = \mathbf{0}, \quad \dots, \quad A\mathbf{v}_n = \mathbf{0} \quad (2)$$

$n \times n$  정방행렬  $V$ 와  $m \times m$  정방행렬  $U$ 를 각각 서로 직교하는 정규벡터  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 과  $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m$

으로 구성되는 직교행렬이라고 하자.

$$\mathbf{V} = [\mathbf{v}_1 \ \mathbf{v}_2 \ \dots \ \mathbf{v}_n], \quad \mathbf{U} = [\mathbf{u}_1 \ \mathbf{u}_2 \ \dots \ \mathbf{u}_m]$$

식 (2)에 나타난 관계를 행렬  $\mathbf{V}$ 와  $\mathbf{U}$ 로 나타내면 다음과 같이 표현할 수 있다.

$$\mathbf{A}\mathbf{V} = \mathbf{U}\mathbf{\Sigma} \quad (3)$$

위에서  $m \times n$  행렬  $\mathbf{\Sigma}$ 는 다음과 같은 형태를 가진다.

$$\mathbf{\Sigma} = \left[ \begin{array}{ccc|c} \sigma_1 & & 0 & \\ & \sigma_2 & & \\ & & \ddots & \\ & 0 & & \sigma_r \\ \hline & 0 & & 0 \end{array} \right] = \begin{bmatrix} \mathbf{\Sigma}_r & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}$$

### 3.2 특이값 분해

이제 행렬  $\mathbf{V}$ 가 직교행렬을 이용하면 다음과 같은 특이값 분해(singular value decomposition)을 정의할 수 있다.

$$\underset{m \times n}{\mathbf{A}} = \underset{m \times m}{\mathbf{U}} \underset{m \times n}{\mathbf{\Sigma}} \underset{n \times n}{\mathbf{V}^t} \quad (4)$$

위의 식 (4)을 전개하면 다음과 같이 계수가 1인 행렬  $\mathbf{u}_k \mathbf{v}_k^t$ 들의 선형조합으로 행렬  $\mathbf{A}$ 를 나타낼 수 있다.

$$\mathbf{A} = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^t + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^t + \dots \sigma_r \mathbf{u}_r \mathbf{v}_r^t \quad (5)$$

또한 식 (3)에서  $\mathbf{\Sigma}$ 에서 0이 되는 값을 제외하면 처음  $r$ 개의 요소들만 이루어진 부분으로만 축소된 특이값 분해를 구할 수 있다.

$$\mathbf{A}\mathbf{V}_r = \mathbf{U}_r \mathbf{\Sigma}_r, \quad \mathbf{A}[\mathbf{v}_1 \ \mathbf{v}_2 \ \dots \ \mathbf{v}_r] = [\mathbf{u}_1 \ \mathbf{u}_2 \ \dots \ \mathbf{u}_r] \begin{bmatrix} \sigma_1 & & 0 \\ & \sigma_2 & \\ & & \ddots \\ & 0 & & \sigma_r \end{bmatrix} \quad (6)$$

위의 식 (6)에서 주의할 점은 행렬  $\mathbf{V}_r$ 과  $\mathbf{U}_r$ 은 정방행렬이 아니고 직교행렬도 아니다.  $\mathbf{V}_r^t \mathbf{V}_r = \mathbf{I}$ 와  $\mathbf{u}_r^t \mathbf{u}_r = \mathbf{I}$ 이 성립하지만 일반적으로  $\mathbf{V}_r \mathbf{V}_r^t \neq \mathbf{I}$ ,  $\mathbf{U}_r \mathbf{U}_r^t \neq \mathbf{I}$ 이다.

## 4 특이값과 특이벡터의 계산

$m \times n$  행렬  $A$ 의 특이값 분해 (4)로 부터 행렬  $A^t A$ 와  $AA^t$ 를 다음과 같이 나타낼 수 있다.

$$A^t A = (V \Sigma^t U^t)(U \Sigma V^t) = V \Sigma^t \Sigma V^t \quad (7)$$

$$AA^t = (U \Sigma V^t)(V \Sigma^t U^t) = U \Sigma \Sigma^t U^t \quad (8)$$

정방행렬의 역행렬은 다음과 같이 행렬식과 여인자 행렬을 이용하여 구한다. 예를 들어 다음과 같은  $2 \times 2$  행렬  $A$ 의 역행렬은

위에서  $A^t A$ 와  $AA^t$ 는 모두 대칭행렬이지만 서로 차원이 다르다. 또한 식 (7) 과 (8)을 보면 두 행렬이 모두  $Q \Lambda Q^t$ 의 형식으로 분해되는 것을 알 수 있다. 즉 다음과 같은 사실을 알 수 있다.

- $n \times n$  비음정치행렬  $A^t A$ 의 고유벡터 행렬은  $V$ 이다.
- $m \times m$  비음정치행렬  $AA^t$ 의 고유벡터 행렬은  $U$ 이다.
- 행렬  $A^t A$ 와  $AA^t$ 의 0이 아닌 고유값은  $\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2$  이다.

따라서 다음과 같은 방법으로 특이값과 특이벡터를 계산할 수 있다. 위의 방법은 두 행렬  $A^t A$ 와  $AA^t$ 를 모두 구하지 않고  $A^t A$ 의 고유값과 고유벡터만으로 특이값 분해를 구하는 방법이다 (만약 행렬  $A$ 가  $100000 \times 5$ 이라면  $AA^t$ 는  $100000 \times 100000$ 이다!)

먼저  $A^t A$ 의 고유벡터  $v_1, \dots, v_r$ 을 다음과 같은 고유값과 고유벡터의 정의로 먼저 구한다.

$$A^t A v_k = \lambda_k v_k = \sigma_k^2 v_k, \quad k = 1, 2, \dots, r \quad (9)$$

다음으로 다음의 식으로  $u_1, \dots, u_r$  를 구한다.

$$u_k = \frac{A v_k}{\sigma_k}, \quad k = 1, 2, \dots, r \quad (10)$$

식 (10)에서 다음과 같이  $u_k$ 가 행렬  $AA^t$ 의 고유벡터임을 확인할 수 있다.


$$AA^t u_k = AA^t \left( \frac{A v_k}{\sigma_k} \right) = A \left( \frac{\sigma_k^2 v_k}{\sigma_k} \right) = \sigma_k^2 u_k$$

또한 식 (9)에서  $v_k$ 는 정규직교벡터이므로 다음과 같이  $u_k$ 도 정규직교행렬임을 보일 수 있다.

$$u_k^t u_l = \left( \frac{A v_k}{\sigma_k} \right)^t \left( \frac{A v_l}{\sigma_l} \right) = \frac{v_k^t (A^t A v_l)}{\sigma_k \sigma_l} = \frac{\sigma_l}{\sigma_k} v_k^t v_l = \begin{cases} 1 & \text{if } k = l \\ 0 & \text{if } k \neq l \end{cases}$$

위에서 구한  $r$ 개의  $v_k$ 와  $u_k$  외에  $n - r$ 과  $m - r$  개의 서로 직교하는 나머지  $v$ 와  $u$ 도 구할 수 있다 (아직 배우지 않았지만 받아들이자!).

## 5 특이값 분해의 기하학적 의미



## 6 예제

### 6.1 예제 7.3

```
A = matrix(c(2,0, 1,1,0,2,1,1,1,1,1,1),3,4,byrow=T)
A

##      [,1] [,2] [,3] [,4]
## [1,]    2    0    1    1
## [2,]    0    2    1    1
## [3,]    1    1    1    1

res <- svd(A, nu=3, nv =4)
res

## $d
## [1] 3.464102 2.000000 0.000000
##
## $u
```

```
##           [,1]           [,2]           [,3]
## [1,] 0.5773503  7.071068e-01 -0.4082483
## [2,] 0.5773503 -7.071068e-01 -0.4082483
## [3,] 0.5773503 -1.110223e-16  0.8164966
##
## $v
##           [,1]           [,2]           [,3]           [,4]
## [1,]  0.5  7.071068e-01 -0.3535534 -0.3535534
## [2,]  0.5 -7.071068e-01 -0.3535534 -0.3535534
## [3,]  0.5  1.110223e-16  0.8535534 -0.1464466
## [4,]  0.5  1.110223e-16 -0.1464466  0.8535534

U <- res$u
U

##           [,1]           [,2]           [,3]
## [1,] 0.5773503  7.071068e-01 -0.4082483
## [2,] 0.5773503 -7.071068e-01 -0.4082483
## [3,] 0.5773503 -1.110223e-16  0.8164966

V <- res$v
V

##           [,1]           [,2]           [,3]           [,4]
## [1,]  0.5  7.071068e-01 -0.3535534 -0.3535534
## [2,]  0.5 -7.071068e-01 -0.3535534 -0.3535534
## [3,]  0.5  1.110223e-16  0.8535534 -0.1464466
## [4,]  0.5  1.110223e-16 -0.1464466  0.8535534

D <- diag(res$d,3,4)
D

##           [,1] [,2] [,3] [,4]
## [1,] 3.464102  0    0    0
## [2,] 0.000000  2    0    0
## [3,] 0.000000  0    0    0
```



```

U %*% D %*% t(V)

##           [,1]           [,2] [,3] [,4]
## [1,]  2.000000e+00 -1.110223e-16    1    1
## [2,] -2.220446e-16  2.000000e+00    1    1
## [3,]  1.000000e+00  1.000000e+00    1    1

```

## 6.2 예제 7.3- 고유값, 고유벡터의 응용

```

A = matrix(c(2,0, 1,1,0,2,1,1,1,1,1,1),3,4,byrow=T)
AtA = t(A) %*% A
AtA

##           [,1] [,2] [,3] [,4]
## [1,]      5     1     3     3
## [2,]      1     5     3     3
## [3,]      3     3     3     3
## [4,]      3     3     3     3

AAt = A %*% t(A)
AAt

##           [,1] [,2] [,3]
## [1,]      6     2     4
## [2,]      2     6     4
## [3,]      4     4     4

eigen(AtA)

## eigen() decomposition
## $values
## [1] 1.200000e+01 4.000000e+00 8.881784e-15 0.000000e+00
##
## $vectors
##           [,1]           [,2] [,3]           [,4]
## [1,]  0.5  7.071068e-01  0.5  0.000000e+00

```

```

## [2,] 0.5 -7.071068e-01 0.5 -6.824628e-17
## [3,] 0.5 9.436896e-16 -0.5 -7.071068e-01
## [4,] 0.5 8.881784e-16 -0.5 7.071068e-01

eigen(AAt)

## eigen() decomposition
## $values
## [1] 1.20000e+01 4.00000e+00 1.24345e-14
##
## $vectors
##          [,1]          [,2]          [,3]
## [1,] -0.5773503 7.071068e-01 -0.4082483
## [2,] -0.5773503 -7.071068e-01 -0.4082483
## [3,] -0.5773503 1.776357e-15 0.8164966

eigvalues <- eigen(AtA)$values
eigvalues

## [1] 1.200000e+01 4.000000e+00 8.881784e-15 0.000000e+00

Sigma = matrix(0,3,4)
Sigma[1,1] = sqrt(eigvalues[1])
Sigma[2,2] = sqrt(eigvalues[2])
Sigma
##          [,1] [,2] [,3] [,4]
## [1,] 3.464102 0 0 0
## [2,] 0.000000 2 0 0
## [3,] 0.000000 0 0 0

V = eigen(AtA)$vectors
V
##          [,1]          [,2] [,3]          [,4]
## [1,] 0.5 7.071068e-01 0.5 0.000000e+00
## [2,] 0.5 -7.071068e-01 0.5 -6.824628e-17
## [3,] 0.5 9.436896e-16 -0.5 -7.071068e-01
## [4,] 0.5 8.881784e-16 -0.5 7.071068e-01

```

```

U = eigen(AAt)$vectors
U

##           [,1]           [,2]           [,3]
## [1,] -0.5773503  7.071068e-01 -0.4082483
## [2,] -0.5773503 -7.071068e-01 -0.4082483
## [3,] -0.5773503  1.776357e-15  0.8164966

U[,1]=-U[,1] # Caution: Some signs must be changed
U

##           [,1]           [,2]           [,3]
## [1,] 0.5773503  7.071068e-01 -0.4082483
## [2,] 0.5773503 -7.071068e-01 -0.4082483
## [3,] 0.5773503  1.776357e-15  0.8164966

U %*% Sigma %*% t(V)

##           [,1]           [,2] [,3] [,4]
## [1,] 2.000000e+00 -1.332268e-15  1  1
## [2,] 4.440892e-16  2.000000e+00  1  1
## [3,] 1.000000e+00  1.000000e+00  1  1

```