

다변량 확률변수의 성질

서울시립대 통계학과 이용희

FALL 2019

1 일변량분포

일변량 확률변수 X 가 확률밀도함수 $f(x)$ 를 가지는 분포를 따를때 기대값과 분산은 다음과 같이 정의된다.

$$E(X) = \int x(x)dx = \mu, \quad V(X) = E[X - E(X)]^2 = \int (x - \mu)^2 f(x)dx = \sigma^2$$

새로운 확률변수 Y 가 확률변수 X 의 선형변환으로 표시된다면 (a 와 b 는 실수)

$$Y = aX + b$$

그 기대값(평균)과 분산은 다음과 같이 계산된다.

$$\begin{aligned} E(Y) &= E(aX + b) \\ &= \int (ax + b)f(x)dx \\ &= a \int xf(x)dx + b \\ &= aE(X) + b \\ &= a\mu + b \\ V(Y) &= Var(aX + b) \\ &= E[aX + b - E(aX + b)]^2 \\ &= E[a(X - \mu)]^2 \\ &= a^2 E(X - \mu)^2 \\ &= a^2 \sigma^2 \end{aligned}$$

2 확률벡터와 분포

확률벡터 \mathbf{X} 가 p 차원의 다변량분포를 따른다고 하고 결합확률밀도함수 $f(\mathbf{x}) = f(x_1, x_2, \dots, x_p)$ 를 를 가진다고 하자.

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \\ X_3 \\ \vdots \\ X_p \end{pmatrix}$$

다변량 확률벡터의 기대값(평균벡터)과 공분산(행렬)은 다음과 같이 계산된다.

$$E(\mathbf{X}) = \begin{pmatrix} E(X_1) \\ E(X_2) \\ E(X_3) \\ \vdots \\ E(X_p) \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{pmatrix} = \boldsymbol{\mu}$$

$$V(\mathbf{X}) = Cov(\mathbf{X}) = E(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^t = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{12} & \sigma_{22} & \dots & \sigma_{2p} \\ \dots & \dots & \dots & \dots \\ \sigma_{1p} & \sigma_{2p} & \dots & \sigma_{pp} \end{pmatrix} = \boldsymbol{\Sigma}$$

여기서 $\sigma_{ii} = V(X_i)$, $\sigma_{ij} = Cov(X_i, X_j) = Cov(X_j, X_i)$ 이다. 따라서 공분산 행렬 $\boldsymbol{\Sigma}$ 는 대칭행렬(symmetric matrix)이다. 다음 공식은 유용한 공식이다.

$$\boldsymbol{\Sigma} = E(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^t = E(\mathbf{X}\mathbf{X}^t) - \boldsymbol{\mu}\boldsymbol{\mu}^t$$

두 확률변수의 상관계수 ρ_{ij} 는 다음과 같이 정의된다.

$$\rho_{ij} = \frac{Cov(X_i, X_j)}{\sqrt{V(X_i)V(X_j)}} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii}\sigma_{jj}}}$$

새로운 확률벡터 \mathbf{Y} 가 확률벡터 \mathbf{X} 의 선형변환이라고 하자.

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$$

단 여기서 $\mathbf{A} = \{a_{ij}\}$ 는 $p \times p$ 실수 행렬이고 $\mathbf{b} = (b_1 b_2 \dots b_p)^t$ 는 $p \times 1$ 실수 벡터이다.

확률벡터 \mathbf{Y} 의 기대값(평균벡터)과 공분산은 다음과 같이 계산된다.

$$\begin{aligned}
 E(\mathbf{Y}) &= E(\mathbf{AX} + \mathbf{b}) \\
 &= \mathbf{AE}(\mathbf{X}) + \mathbf{b} \\
 &= \mathbf{A}\boldsymbol{\mu} + \mathbf{b} \\
 V(\mathbf{Y}) &= \text{Var}(\mathbf{AX} + \mathbf{b}) \\
 &= E[\mathbf{AX} + \mathbf{b} - E(\mathbf{AX} + \mathbf{b})][\mathbf{AX} + \mathbf{b} - E(\mathbf{AX} + \mathbf{b})]^t \\
 &= E[\mathbf{AX} - \mathbf{A}\boldsymbol{\mu}][\mathbf{AX} - \mathbf{A}\boldsymbol{\mu}]^t \\
 &= E[\mathbf{A}(\mathbf{X} - \boldsymbol{\mu})][\mathbf{A}(\mathbf{X} - \boldsymbol{\mu})]^t \\
 &= \mathbf{AE}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^t]\mathbf{A}^t \\
 &= \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^t
 \end{aligned}$$

만약 표본 $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ 이 독립적으로 평균이 $\boldsymbol{\mu}$ 이고 공분산이 $\boldsymbol{\Sigma}$ 인 분포에서 추출되었다면 표본의 평균벡터 $\bar{\mathbf{X}}$ 는 평균이 $\boldsymbol{\mu}$ 이고 공분산이 $\frac{1}{n}\boldsymbol{\Sigma}$ 인 분포를 따른다.

$$\bar{\mathbf{X}} = \begin{pmatrix} \sum_{i=1}^n X_{i1}/n \\ \sum_{i=1}^n X_{i2}/n \\ \sum_{i=1}^n X_{i3}/n \\ \vdots \\ \sum_{i=1}^n X_{ip}/n \end{pmatrix}$$

여기서 X_{ij} 는 i 번째 표본벡터 $\mathbf{X}_i = (X_{i1} X_{i2} \dots X_{ip})^t$ 의 j 번째 확률변수이다.

3 다변량 정규분포

일변량 확률변수 X 가 평균이 μ 이고 분산이 σ^2 인 정규분포를 따른다면 다음과 같이 나타내고

$$X \sim N(\mu, \sigma^2)$$

확률밀도함수 $f(x)$ 는 다음과 같이 주어진다.

$$f(x) = (2\pi\sigma^2)^{-1/2} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

p -차원 확률벡터 \mathbf{X} 가 평균이 $\boldsymbol{\mu}$ 이고 공분산이 $\boldsymbol{\Sigma}$ 인 다변량 정규분포를 따른다면 다음과 같이 나타내고

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

확률밀도함수 $f(\mathbf{x})$ 는 다음과 같이 주어진다.

$$f(\mathbf{x}) = (2\pi)^{-p/2} |\boldsymbol{\Sigma}|^{-1/2} \exp \left(-\frac{(\mathbf{x} - \boldsymbol{\mu}) \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})^t}{2} \right)$$

다변량 정규분포 $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 를 따르는 확률벡터 \mathbf{X} 를 다음과 같이 두 부분으로 나누면

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}, \quad \mathbf{X}_1 = \begin{bmatrix} \mathbf{X}_{11} \\ \mathbf{X}_{12} \\ \vdots \\ \mathbf{X}_{1p} \end{bmatrix}, \quad \mathbf{X}_2 = \begin{bmatrix} \mathbf{X}_{21} \\ \mathbf{X}_{22} \\ \vdots \\ \mathbf{X}_{2q} \end{bmatrix}$$

각각 다변량 정규분포를 따르고 다음과 같이 나타낼 수 있다.

$$\begin{bmatrix} E(\mathbf{X}_1) \\ E(\mathbf{X}_2) \end{bmatrix} = \begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \quad \begin{bmatrix} V(\mathbf{X}_1) & Cov(\mathbf{X}_1, \mathbf{X}_2) \\ Cov(\mathbf{X}_2, \mathbf{X}_1) & V(\mathbf{X}_2) \end{bmatrix} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{12}^t & \boldsymbol{\Sigma}_{22} \end{bmatrix}$$

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_{p+q} \left(\begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{12}^t & \boldsymbol{\Sigma}_{22} \end{bmatrix} \right)$$

확률벡터 $\mathbf{X}_2 = \mathbf{x}_2$ 가 주어진 경우 \mathbf{X}_1 의 조건부 분포는 p -차원 다변량 정규분포를 따르고 평균과 공분산은 다음과 같다.

$$E(\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2) = \boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{x}_2 - \boldsymbol{\mu}_2), \quad V(\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2) = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{12}^t$$

예를 들어 2-차원 확률벡터 $\mathbf{X} = (X_1, X_2)^t$ 가 평균이 $\boldsymbol{\mu} = (\mu_1, \mu_2)^t$ 이고 공분산 $\boldsymbol{\Sigma}$ 가 다음과 같이 주어진

$$\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{22} \end{pmatrix}$$

이변량 정규분포를 따른다면 확률밀도함수 $f(\mathbf{x})$ 에서 exp함수의 인자는 다음과 같이 주어진다.

$$\begin{aligned} & (\mathbf{x} - \boldsymbol{\mu}) \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})^t = \\ & -\frac{1}{2(1-\rho^2)} \left[\left(\frac{(x_1 - \mu_1)^2}{\sigma_{11}} \right) + \left(\frac{(x_2 - \mu_2)^2}{\sigma_{22}} \right) - 2\rho \left(\frac{(x_1 - \mu_1)}{\sqrt{\sigma_{11}}} \right) \left(\frac{(x_2 - \mu_2)}{\sqrt{\sigma_{22}}} \right) \right] \end{aligned}$$

그리고 $p = 2$ 인 경우 확률밀도함수의 상수부분은 다음과 같이 주어진다.

$$(2\pi)^{-p/2} |\boldsymbol{\Sigma}|^{-1/2} = \frac{1}{2\pi \sqrt{\sigma_{11}\sigma_{22}(1-\rho^2)}}$$

여기서 $\rho = \sigma_{12} / \sqrt{\sigma_{11}\sigma_{22}}$

만약 $X_2 = x_2$ 가 주어졌을 때 X_1 의 조건부 분포는 정규분포이고 평균과 분산은 다음과 같이 주어진다.

$$E(X_1|X_2 = x_2) = \mu_1 + \frac{\sigma_{12}}{\sigma_{22}}(\mu_2 - x_2) = \mu_1 + \rho \frac{\sqrt{\sigma_{11}}}{\sqrt{\sigma_{22}}}(\mu_2 - x_2)$$

$$V(X_1|X_2 = x_2) = \sigma_{11} - \frac{\sigma_{12}^2}{\sigma_{22}} = \sigma_{11}(1 - \rho^2)$$

다변량 정규분포에서 공분산이 0인 두 확률 변수는 독립이다.

$$\sigma_{ij} = 0 \leftrightarrow X_i \text{ and } X_j \text{ are independent}$$

4 표준정규분포로의 변환

일변량 확률변수 X 가 평균이 μ 이고 분산이 σ^2 인 경우 다음과 같은 선형변환을 고려하면.

$$Z = \frac{X - \mu}{\sigma} = (\sigma^2)^{-1/2}(X - \mu)$$

확률변수 Z 는 평균이 0 이고 분산이 1인 분포를 따른다.

p 차원 확률벡터 \mathbf{X} 가 평균이 $\boldsymbol{\mu}$ 이고 공분산이 $\boldsymbol{\Sigma}$ 인 분포를 가진다고 가정하자. 공분산 행렬 $\boldsymbol{\Sigma}$ 는 양정치 행렬 (positive definite matrix)이며 다음과 같은 행렬의 분해가 가능하다.

$$\boldsymbol{\Sigma} = \mathbf{C}\mathbf{C}^t$$

여기서 \mathbf{C} 는 정칙행렬이며 역행렬 \mathbf{C}^{-1} 가 존재한다. 위와 같은 행렬의 분해는 스펙트럴 분해(spectral decomposition)을 이용하여 구할 수 있다. 공분산 행렬 $\boldsymbol{\Sigma}$ 는 양정치 행렬이므로 고유치(eigen value) $(\lambda_1, \lambda_2, \dots, \lambda_p)$ 가 모두 양수이고 정규직교 고유벡터(orthonormal eigen vector)의 행렬 \mathbf{P} 을 이용하여 다음과 같은 분해가 가능하다.

$$\boldsymbol{\Sigma} = \mathbf{P}\boldsymbol{\Lambda}\mathbf{P}^t = \mathbf{P}\boldsymbol{\Lambda}^{1/2}\boldsymbol{\Lambda}^{1/2}\mathbf{P}^t$$

여기서 $\boldsymbol{\Lambda}$ 는 고유치 $(\lambda_1, \lambda_2, \dots, \lambda_p)$ 를 대각원소로 가지는 대각행렬이며 $\boldsymbol{\Lambda}^{1/2}$ 는 고유치의 제곱근을 대각원소로 가지는 대각행렬이다. 따라서 $\mathbf{C} = \mathbf{P}\boldsymbol{\Lambda}^{1/2}$ 로 하면 위와 같은 행렬의 분해가 가능하다. 정규직교 고유벡터 (orthonormal eigen vector)의 행렬 \mathbf{P} 는 직교행렬이므로

$$\mathbf{C}^{-1} = (\mathbf{P}\boldsymbol{\Lambda}^{1/2})^{-1} = \boldsymbol{\Lambda}^{-1/2}\mathbf{P}^t$$

p 차원 확률벡터 \mathbf{X} 의 다음과 같은 선형변환을 고려하면.

$$\mathbf{Z} = \mathbf{C}^{-1}(\mathbf{X} - \boldsymbol{\mu}) = \boldsymbol{\Lambda}^{-1/2}\mathbf{P}^t(\mathbf{X} - \boldsymbol{\mu})$$

확률벡터 \mathbf{Z} 는 평균이 $\mathbf{0}$ 이고 공분산이 \mathbf{I} 인 분포를 따른다 (why?).

확률벡터 \mathbf{X} 가 정규분포를 따른다면 선형변환한 확률벡터 \mathbf{Z} 도 정규분포를 따른다.

5 예제

예를 들어 이변량확률벡터 \mathbf{X} 가 다음과 같은 평균벡터와 공분산을 가진 정규분포를 따른다고 하자

$$\boldsymbol{\mu} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \quad \boldsymbol{\Sigma} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

공분산행렬 $\boldsymbol{\Sigma}$ 의 고유치는 $|\boldsymbol{\Sigma} - \lambda \mathbf{I}| = 0$ 의 방정식을 풀어 구할 수 있다.

$$|\boldsymbol{\Sigma} - \lambda \mathbf{I}| = \begin{vmatrix} 2-\lambda & 1 \\ 1 & 2-\lambda \end{vmatrix} = \lambda^2 - 4\lambda + 3 = 0$$

방정식을 풀면 고유치는 $(\lambda_1, \lambda_2) = (3, 1)$ 이다. 각 고유치에 대한 고유벡터 $\mathbf{p} = (p_1, p_2)^t$ 는 $\boldsymbol{\Sigma}\mathbf{p} = \lambda\mathbf{p}$ 으로 구할 수 있다. 각 고유치에 대하여 방정식을 구하면 다음 두 개의 방정식을 얻을 수 있다.

$$p_1 - p_2 = 1 \text{ and } p_1 + p_2 = 0$$

정규직교 벡터의 조건을 만족 시키기 위해서 $p_1^2 + p_2^2 = 1$ 의 조건을 적용하면 다음과 같은 정규직교 고유행렬을 얻을 수 있다.

$$\mathbf{P} = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}$$

또한

$$\boldsymbol{\Lambda} = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix} \quad \boldsymbol{\Lambda}^{1/2} = \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \end{pmatrix}$$

따라서 $\mathbf{C}^{-1} = \boldsymbol{\Lambda}^{-1/2}\mathbf{P}^t$ 이며

$$\mathbf{C}^{-1} = \boldsymbol{\Lambda}^{-1/2}\mathbf{P}^t = \begin{pmatrix} \frac{1}{\sqrt{3}} & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} = \begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}$$

위의 계산을 R 프로그램으로 다음과 같이 구현할 수 있다.

```
mu <- c(1,2)
S <- matrix(c(2,1,1,2),2,2)
res<- eigen(S)
res

## eigen() decomposition
## $values
## [1] 3 1
##
## $vectors
```

```

##           [,1]      [,2]
## [1,] 0.7071068 -0.7071068
## [2,] 0.7071068  0.7071068

L <- res$values
P <- res$vectors
Lsqr <- diag(sqrt(L))
C <- P %*% Lsqr
C

##           [,1]      [,2]
## [1,] 1.224745 -0.7071068
## [2,] 1.224745  0.7071068

Cinv <- solve(C)
Cinv

##           [,1]      [,2]
## [1,] 0.4082483 0.4082483
## [2,] -0.7071068 0.7071068

Cinv %*% S %*% t(Cinv)

##           [,1] [,2]
## [1,]      1      0
## [2,]      0      1

```